

# Masked Autoencoders Are Scalable Vision Learners

He et al. – Facebook AI Research (FAIR) | arXiv 2021

Noé BARRANGER · Cédric GAUTHERET · Romain AMIGON

01

## Contexte & motivation

Pourquoi l'auto-encodage masqué pour la vision ?

03

## Entrainement

ImageNet

05

## Résultats clés

ImageNet, détection d'objets, segmentation, transfert

02

## Architecture MAE

Encodeur asymétrique, décodeur léger, cible de reconstruction

04

## Ablations

Ratio de masquage, design du décodeur, cible pixel


06

## Forces & limites

Analyse critique du papier

Vision par ordinateur dominée par apprentissage supervisé, label coûteux à obtenir

Partie apprentissage auto-supervisé (SSL) est avant 2021 dominée par les méthodes contrastives (SimCLR, MoCo, BYOL) qui reposent sur de l'augmentation de donnée complexe et lourde, nécessite beaucoup d'exemple négatifs en même temps donc grande taille de batch



BERT (NLP) introduit Masked Language Modeling : masquer une partie de la phrase et prédire les mots manquants

Idée de l'article est de transposer cette idée simple aux images = MAE

MAE  $\rightarrow$  I-JEPA





Image divisée en patch et masquage d'au moins 75% = apprendre la sémantique et pas interpolation locale

Auto-Encodeur Asymétrique

Encodeur voit 25% et produit une représentation latente

Décodeur doit produire 100%, si aussi gros que encodeur alors explosion du calcul



### Encodeur

ViT (MHA + MLP) 24 à 32 blocs


Pour conserver l'information spatiale, on ajoute un encodage positionnel 2D (sinusoidal) à l'encodeur

### Décodeur


ViT 8 blocs

Shared Masked Token = vecteur appris commun à tous les patch masqués + réinjection du PE pour unicité

couche linéaire pour projection dans les bonnes dimensions



ViT particulièrement adapté par aux CNN car fonctionne déjà avec des patch/token donc on ne fournit pas la partie manquante contrairement au CNN où l'opération de convolution se propagerait sur les données manquantes



batches visibles  
de l'image  
(améliore  
rapidité et  
précision)

image entière  
avec mask

Loss : MSE image original - reconstruite des  
pixels normalisés calculé que sur les mask  
optimizer : AdamW  
momentum optim :  $\beta_1, \beta_2 = 0.9, 0.95$   
base lr :  $1.5e-4$   
 $lr = \text{base\_lr} * \text{batchsize} / 256$   
Schedule : Décroissance en cosinus  
Warmup : 40 epochs

taux de masquage  $\leq 75\%$

Batch size = 4096

800 épochs


Weight decay = 0.05

Peu de data augmentation :

-recadrage aléatoire redimensionné (RandomResizedCrop) avec retournement horizontal est utilisé.  
(variation de couleur dégrade. Le masquage aléatoire compense la data augmentation)

Pas de Drop path ni gradient clipping

Ratio de masquage — Fine-tuning vs Linear Probing (ViT-L)



### Décodeur

8 blocs, 512 dim. → seulement 9 % du FLOP de l'encodeur. La profondeur du décodeur impacte surtout le linear probing (↑8 %).


### Mask token dans l'encodeur ?



Si on inclut les mask tokens dans l'encodeur : -14 % en linear probing et +3× de calcul. Asymétrie = clé du gain.

### Cible de reconstruction

Pixels normalisés par patch  $\approx$  tokens dVAE, plus simples et sans dVAE pré-entraîné sur 250M images.







| Méthode    | Données pré-entr. | ViT-B       | ViT-L       | ViT-H       |
|------------|-------------------|-------------|-------------|-------------|
| Scratch    | —                 | 82.3        | 82.6        | 83.1        |
| DINO       | IN1K              | 82.8        | —           | —           |
| MoCo v3    | IN1K              | 83.2        | 84.1        | —           |
| BEiT       | IN1K + DALLE      | 83.2        | 85.2        | —           |
| <b>MAE</b> | <b>IN1K</b>       | <b>83.6</b> | <b>85.9</b> | <b>86.9</b> |

# 87.8 %

ViT-H 448px — SOTA  
sur ImageNet-1K

# 3-4×

accélération du pré-entraînement  
vs ViT standard

### Forces

Simplicité: pas d'opérations sparse, pas de tokenizer externe.

Scalabilité démontrée :  $B \Rightarrow L \Rightarrow H$  avec gains continus et stables.

Capacité de transfert supérieur au supervisé en détection et segmentation.

Indépendance à l'augmentation, contrairement aux méthodes contrastives.

### Limites

Infrastructure lourde : ViT-H requiert 128 TPU-v3.

Linear probing < méthodes contrastives (MoCo v3) : représentations moins linéairement séparables.

Généralisation hors-domaine non évaluée : l'hypothèse de redondance spatiale à 75% peut ne pas tenir en imagerie médicale, satellite ou documentaire.

# Conclusion

## MAE : une idée simple, un impact majeur

Masquer 75 % des patches force une compréhension de la scène, sans augmentation complexe ni tokenizer externe.

## Scalabilité réelle

Les gains s'accroissent avec la taille du modèle — comportement aligné avec GPT/BERT en NLP.

## Limites à garder en tête

Linear probing < contrastif, infrastructure coûteuse, évaluation centrée ImageNet.