

Présentation des reproductions

Noé BARRANGER · Cédric GAUTHERET · Romain AMIGON

<https://github.com/Jenca750/8INF974-APIA2.git>

01

MAE

Architecture, Processus reproduction,
Comparaison, Résultats

02



I-JEPA

Architecture, Processus reproduction,
Comparaison, Résultats

03



LeWorldModel

Architecture, Processus reproduction,
Comparaison, Résultats





01 · MAE - Images obtenues

4




	Article MAE	Implémentation maison MAE
Résolution Images	224x224 (ImageNet)	32x32x60000 (CIFAR-10)
Taille Patch	16x16	4x4
Embedding	1024	192
Depth enc	24	12
Heads enc	16	3
Embed dim dec	512	96
Depth dec	8	4
Mask ratio	75%	75%
Epochs	1600	50




1 h , 50 epochs,
pré-entraînement MAE


	Article MAE	Implémentation maison MAE
Linear probe	73.5%	49.6%
Fine-tuning	86.9%	83.6%

Confusion Matrix — Linear Probe (CIFAR-10)



Confusion Matrix — Fine-tuning (CIFAR-10, 83.6%)





$$x \rightarrow s_x = f_\theta(x)$$

$$y \rightarrow s_y = f_{\bar{\theta}}(y)$$

$$\hat{s}_y = P_\phi(s_x, z)$$



$$\text{MSE}(s_y, \hat{s}_y)$$


Target Encoder mis à jour par EMA

Multi-Block Masking = grands blocs (15-20% x4) puis échantillonnage en 1 seul bloc (85-95%)


	Article I-JEPA	Implémentation maison I-JEPA
Résolution Images	224x224 (ImageNet)	64x64 (TinyImageNet)
Taille Patch	16x16	4x4
Embedding	1024	192
Depth	24	12 (6 prédicteur)
Modèle	ViT-L, ViT-H, ViT-G	ViT-T
Hardware	16 GPU A100 (80Go)	RTX 4070Ti (12Go)
Epoques	600 (72h)	20 (7h)
Décodeur visualisation	Modèle Diffusion (RCDM)	Upsampling MLP
Classification	ImageNet 1000 classes	TinyImageNet restreint à 10 classes

AdamW
pas de Warmup
7h, époques 5 par 5 (VRAM)






Accuracy 18%



Semi-Supervised ImageNet-1K 1% Evaluation vs GPU Hours




JEPA souffrent de collapse :

L'encodeur est inefficace


introduction de nombreuses métriques (6-9) pour compenser

Objectif :

Avoir un World Model sur des images avec un seul hyperparamètre, la loss de régularisation (SIGReg)




Forcer la distribution globale des vecteurs latents à ressembler à une distribution Gaussienne isotrope standard $N(0, I)$.
l'encodeur ne *peut plus* ignorer les objets dynamiques







Encodeur : Vit-Tiy, 5M param

Decodeur : Transformer, 10M param

entrainement : GPU unique grand
public, 48x plus rapides que les WM





Encodeur : 12 couches, 4 têtes

Decodeur : 4 couhes, 8 têtes (au lieu de 6 et 16)




Sigreg: 256 au lieu de 1024

entrainement :40 epochs au lieu de 10 + rajout de fine tuning pour T push

03 - LeWorldModel - Mon implémentation plus grande

18

num_layers=6, nhead=16, 10 epochs





Encodeur (Probing) : Effondrement dimensionnel. $\text{state}[0]$ $R^2=0.89$, mais $\text{state}[1]$ totalement ignoré $R^2 = 0$.

Prédicteur : Stable, dérive de 2.46, *mais il prédit sur un espace latent aveugle*.

Planning (CEM) : Échec total (0%).

avec fine tuning sur
couleur autre que blanc



Two rooms

Encodeur (Probing) : Espace latent expressif. L'agent est bien capté (Corrélation linéaire $r = 0.80$, voire $r=0.97$ en non-linéaire).

Prédicteur : Dynamique temporelle très stable (MSE très faible de 0.01, dérive contenue à 2.75 sur 3 pas).

Planning (CEM) : **Succès à 96.7%**. L'algorithme converge et réduit la distance au but de 97%.

